

Research Design

Maik

January 2026

1 Research Design

Diese Arbeit folgt einem kontrollierten, vergleichenden experimentellen Research Design zur Untersuchung der Leistungsfähigkeit Large Language Models (LLMs) bei der Durchführung use-case-basierter Software-Inspektionen. Ziel ist es, die Effektivität und Fehlerabdeckung verschiedener LLMs unter identischen Inspektionsbedingungen systematisch zu analysieren.

1.1 Zielsetzung der Studie

Ziel der Studie ist es, zu untersuchen, inwieweit Large Language Models in der Lage sind, Fehler in Software-Dokumenten zu identifizieren, wenn sie eine strukturierte Inspektionsmethode nach dem Usage-Based Reading (UBR) Ansatz anwenden. Dabei werden mehrere LLMs miteinander verglichen, um Unterschiede in der Fehlererkennung, Fehlerklassifikation und Fehlerabdeckung zu analysieren.

1.2 Forschungsfragen

Die Untersuchung wird durch die folgenden Forschungsfragen geleitet:

- **RQ1:** Wie effektiv sind verschiedene Large Language Models bei der Identifikation von Fehlern in Software-Dokumenten unter Verwendung des Usage-Based Reading Ansatzes?
- **RQ2:** Unterscheiden sich die betrachteten LLMs hinsichtlich der Anzahl und Art der identifizierten Fehler?
- **RQ3:** Welche Fehlerklassen (kritisch, wichtig, geringfügig) werden von den LLMs bevorzugt erkannt?
- **RQ4:** In welchem Ausmaß überschneiden sich die von unterschiedlichen LLMs identifizierten Fehler?

1.3 Untersuchungsobjekte

Gegenstand der Untersuchung sind Software-Dokumente, die aus einem textuellen Anforderungsdokument, einem Software-Design-Dokument sowie einem zugehörigen Use-Case-Dokument bestehen. Die Use Cases sind vorab priorisiert und dienen als primäres Führungsinstrument für die Inspektion.

1.4 Experimentelles Setup

Das experimentelle Setup ist so gestaltet, dass alle untersuchten LLMs unter identischen Bedingungen eingesetzt werden. Jedes Modell erhält dieselben Inspektionsartefakte sowie denselben Inspektionsplan. Die LLMs übernehmen dabei die Rolle eines einzelnen Inspektors und führen die Inspektion autonom durch.

1.5 Variablen

1.5.1 Unabhängige Variable

Die unabhängige Variable der Studie ist das eingesetzte Large Language Model. Mehrere Modelle werden ausgewählt, um einen vergleichenden Ansatz zu ermöglichen.

1.5.2 Abhängige Variablen

Die abhängigen Variablen werden aus den ausgefüllten Inspection Records abgeleitet und umfassen:

- Gesamtanzahl identifizierter Fehler
- Anzahl identifizierter Fehler pro Fehlerklasse (A, B, C)
- Anteil kritischer Fehler (Klasse A)
- Anzahl einzigartiger Fehler pro Modell
- Überlappung der identifizierten Fehler zwischen den Modellen

1.5.3 Kontrollvariablen

Zur Sicherstellung der Vergleichbarkeit werden folgende Variablen konstant gehalten:

- verwendete Software-Dokumente
- priorisierte Use Cases
- Inspektionsplan und Vorgehensweise
- Fehlerdefinition und Fehlerklassifikation
- Inspektionsartefakte und Dokumentenstruktur

1.6 Datenerhebung

Die Datenerhebung erfolgt durch die Durchführung use-case-basierter Software-Inspektionen mittels LLMs. Die Ergebnisse jeder Inspektion werden in einem standardisierten Inspection Record dokumentiert, der insbesondere detaillierte Fehlerlogs enthält.

1.7 Datenauswertung

Die Auswertung der erhobenen Daten erfolgt primär deskriptiv. Die Ergebnisse werden in tabellarischer und grafischer Form dargestellt und zwischen den betrachteten LLMs verglichen. Zusätzlich wird eine qualitative Analyse der identifizierten Fehler durchgeführt, um Unterschiede in der Art der erkannten Fehler zu untersuchen.

1.8 Reproduzierbarkeit

Das Research Design ist so gestaltet, dass die Studie reproduzierbar ist. Alle Modelle erhalten identische Eingaben, Artefakte und Instruktionen. Der gesamte Inspektionsprozess ist deterministisch beschrieben, sodass die Ergebnisse nachvollziehbar und vergleichbar sind.